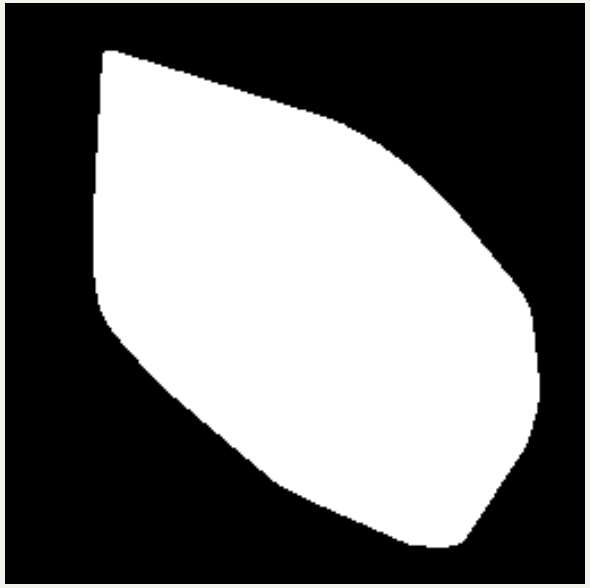
Rozpoznawanie chorób liści ziemniaka

Kolor, tekstura i kształt
w klasycznym uczeniu maszynowym



Lab 1. Klasyfikacja według kształtu



Maska liścia jako ilustracja metody

Pole, obwód, zwartość
Prosty opis sylwetki

Deskryptory Fouriera
Opis konturu

Centrowanie i skalowanie
Porównanie wariantów + kNN / SVM

Możliwe rozwiązanie ćwiczenia; bez głębokich sieci

Lab 2. Klasyfikacja według tekstur



Gładsza powierzchnia



Nieregularne plamy

GLCM + kNN / SVM
Kontrast, energia, jednorodność

Przesuwne okno
Propozycja segmentacji tekstur

Porównanie z GLRLM
Długości serii podobnych pikseli

Możliwe rozwiązanie dla 4–5 klas; zdjęcia liści ilustrują różnicę tekstur

Dwa zadania rozpoznawania liści



Zdrowy



Alternarioza
Early blight



Zaraza ziemniaka
Late blight

Proste · 305 zdjęć
Zdrowy / alternarioza

Trudne · 2000 zdjęć
Alternarioza / zaraza ziemniaka

Pipeline użyty w eksperymentach



Zdjęcie RGB

Wejście





Maska liścia

Usunięcie tła





50 cech

Kolor + tekstura + kształt





Klasyfikator

StandardScaler + model

Porównujemy trzy warianty obrazu

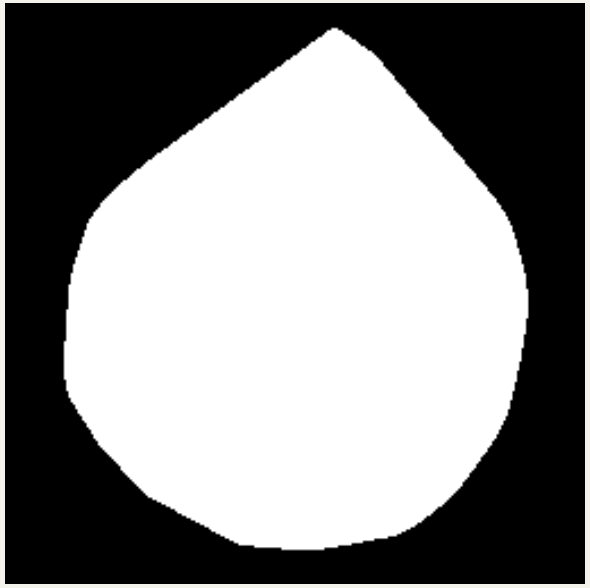
Sama maska / **+ min–max** / **+ Gaussian, CLAHE i min–max**

Maska powstaje na oryginale i pozostaje taka sama we wszystkich wariantach

Typowy liść: oddzielenie od tła



Oryginał



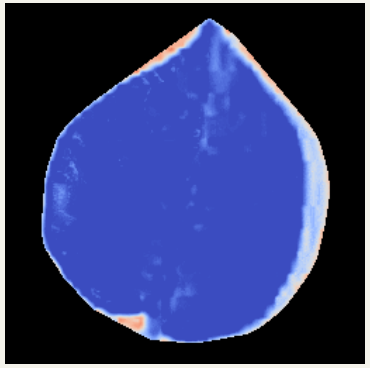
Maska



Po przetworzeniu

Otsu + morfologia + otoczka wypukła największego konturu

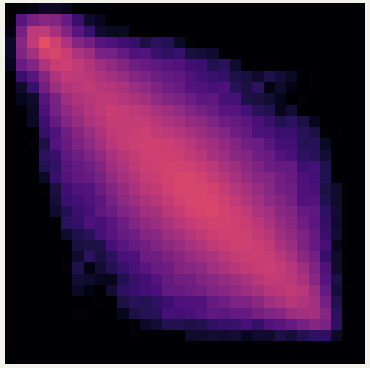
Co opisuje 50 cech?



Kolor Lab

6

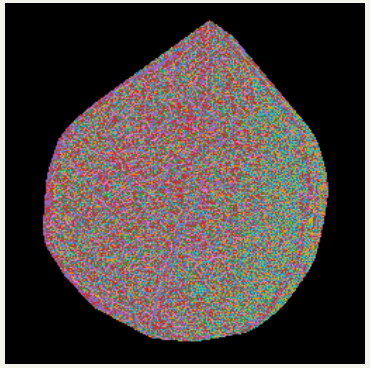
Średnie i odchylenia



Tekstura GLCM

12

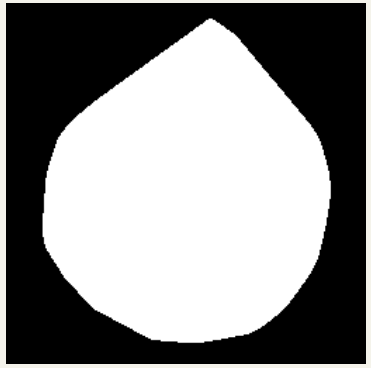
Pary jasności pikseli



Tekstura LBP

28

Lokalne wzorce



Kształt

4

Geometria maski

W zapisanej analizie największy wpływ ma kolor

Ważność: spadek F1 macro po permutacji grupy cech na teście

Jak ocenialiśmy modele?

Uczenie · około 70%

5-fold CV + dobór parametrów

Test · około 30%

Ocena po wyborze konfiguracji

Proste: **212 / 93** Trudne: **1400 / 600**

Wybór konfiguracji według F1 macro w CV

Grupowanie chroni przed identycznymi obrazami; różne zdjęcia tego samego liścia mogą trafić do obu części

Zysk z preprocessingu zależy od modelu

F1 macro w CV · sama maska i wariant Gaussian + CLAHE + min–max

	Sama maska	Pełny wariant	Zmiana
SVM RBF · proste	0,9811	0,9906	+0,94 pp
SVM RBF · trudne	0,9714	0,9721	+0,07 pp
kNN · proste	0,9573	0,9196	−3,78 pp
kNN · trudne	0,9421	0,9235	−1,86 pp

W zadaniu trudnym poprawa SVM jest niewielka

Wyniki na zbiorze testowym

Accuracy testowa · skala wykresu 90–100%

Model	Zadanie proste	Zadanie trudne
SVM · RBF	**97,8%**	**96,7%**
SVM · liniowy	97,8%	96,3%
Regresja logistyczna	96,8%	96,8%
Random Forest	96,8%	94,8%
kNN	94,6%	93,3%

SVM wygrywa w CV; regresja logistyczna ma o 1 trafienie więcej na trudnym teście

Trudny przypadek: pomyłka wszystkich modeli



Etykieta:
alternarioza



Predykcja:
zaraza ziemniaka

SVM RBF · trudny test

	Alt.	Zar.
Alt.	291	9
Zar.	11	289

Wiersze: etykiety
Kolumny: predykcje

6 zdjęć w trudnym teście pomyliło wszystkie 5 modeli

Wnioski i dalsze kroki

- Klasyczne modele dobrze rozdzielają klasy **w tym zbiorze**
- Najwięcej informacji wnosi **kolor**